

Remédiation et Gouvernance de Données pour l'Entrainement de Large Language Model (LLM)

Table des matières

Résumé.....	4
Remerciements	5
Introduction.....	6
L'Oréal et ses enjeux d'innovation	6
Problématique.....	7
1. Cadre industriel, scientifique et technique du stage.....	9
1.1 Positionnement du stage au sein de l'équipe Data.....	9
1.2 Positionnement technique	9
1.3 Brève introduction aux missions du stage	13
1.3.1 Règles métiers, un levier pour la gouvernance et remédiation de données ..	13
1.3.2 Analyse et remédiations des données	14
1.3.3 L'Industrialisation de flux de données	14
2. Mise en œuvre technique des travaux réalisés.....	15
2.1 Analyse, qualification et synchronisation des règles métiers	15
2.1.1 Analyse du référentiel existant.....	15
2.1.2 Comparaison avec les éléments documentés dans R2D2.....	17
2.1.3 Vérification de distinction entre Business Rule et Predictivity Use Case	19
2.2 Remédiation des données de formule	20
2.2.1 Analyse préliminaire	20
2.2.3 Méthodologie de correction	21
2.2.4 Résultats obtenus sur les jeux de données traités	23
2.3 Industrialisation de flux de données	24
2.3.1 Périmètre de la cartographie et choix méthodologique	24
2.3.2 Structure du référentiel de mapping SDDS → CDS	25
2.3.3 Analyse des chaînes de transformation SQL et traçabilité de la lignée des attributs.....	26
3. Résultats, expérimentation et validation	27
3.1 Méthodologie d'évaluation.....	27

3.2 Critères de validation retenus	27
3.3 Analyse critique des résultats	28
3.4 Limites des travaux réalisés et points de vigilance	29
4. Analyse des enjeux environnementaux et sociétaux	29
4.1 Enjeux liés à l'exploitation massive des données	29
4.2 Enjeux environnementaux des approches fondées sur l'intelligence artificielle .	30
4.3 Enjeux sociétaux liés à la fiabilité, à la gouvernance et à la traçabilité des données	31
5. Conclusion et perspectives	31
5.1 Difficultés rencontrées au cours du stage	31
5.2 Enseignements tirés de l'expérience	32
5.3 Apport du stage dans le projet professionnel	33
Glossaire	34
Bibliographie.....	37
Annexe I.....	38
Annexe II.....	39
Annexe III.....	41

Résumé

La Transformation Digitale de la Recherche et Innovation cosmétique utilise l'Intelligence Artificielle comme un levier incontournable pour optimiser les processus de formulation. Ce travail contribue au développement d'un Formulation Foundation Model, un grand modèle de langage (LLM) dédié à la formulation, il s'agit d'un modèle d'apprentissage automatique à grande échelle né d'une collaboration entre la R&I de L'Oréal et IBM Research, conçu pour assister les formulateurs dans la génération et l'optimisation de formulations cosmétiques.

L'un des défis centraux de ce projet tient à la qualité et à la traçabilité des données mobilisées pour l'entraînement du modèle. Un manque d'harmonisation dans la labélisation et la structuration des données issues de différentes sources, combiné à une qualité parfois variable des mesures ou à un déficit de représentativité, peut constituer un frein substantiel à la robustesse et à la précision du modèle, dégradant in fine la pertinence des prédictions de performance et la qualité des formulations proposées.

Mes missions durant ce stage ont consisté en trois axes complémentaires : l'analyse et la remédiation de la qualité des données, la coordination des actions de remédiation avec les experts métiers, et la production d'un référentiel de spécifications autoporteur documentant les flux de données à travers les différentes couches d'exposition des données. Ce référentiel vise à garantir la continuité et l'évolutivité opérationnelle du projet et sa pérennité face aux évolutions des équipes intervenantes ou aux évolutions dans la structuration ou le stockage des données en amont.

.

Remerciements

Le projet était déjà engagé depuis un an et demi lorsque j'ai démarré mon stage. La simple exploration de la première couche de données m'a permis de comprendre la mesure de la complexité de l'environnement. Il y a de très nombreuses tables et schémas.

À ce stade, j'ai formulé de nombreuses questions, y compris certaines qui pourraient paraître élémentaires. Je tiens à exprimer ma sincère gratitude envers celles et ceux qui ont eu la générosité de répondre à mes nombreuses interrogations, et tout particulièrement Sophie Dereuddre, ma Responsable de Stage, ainsi que les membres du Cluster Data Acquisition : Sarah, Christine, William et Benjamin.

A ne pas oublier :

Ma tutrice de l'école, Aicha Nabila, qui a participé à des réunions organisées, la rencontre à mi-parcours, et m'a apporté conseils et soutien tout au long de mon premier vrai essai à grande échelle dans le monde professionnel intégrant l'Ingénierie.

Les collègues qui ont pu alimenter mes réflexions, aussi bien agréables que scientifiques et informatives. Merci pour les pauses café, les échanges même simples, les bonnes pratiques et les petites attentions.

Merci beaucoup pour l'accueil de l'Oréal et surtout pour l'INSA Lyon pendant tout mon cursus. Merci de m'avoir donné la chance pour prouver que je suis capable de faire quelque chose qui m'inspirait, peu importe où la vie me ramènerait dans la suite. Je rends grâce au Dieu, l'univers, le destin, ou bien le hasard selon ce en quoi chacun choisit de croire pour tout de bout en bout et dans ses moindres détails.

Merci à tous.

Introduction

L'Oréal et ses enjeux d'innovation

Fondée en 1909 par le chimiste français Eugène Schueller, L'Oréal est un leader mondial du secteur de la beauté et de la cosmétique. Visionnaire, il créa la première teinture capillaire synthétique sûre, jetant ainsi les bases d'un empire industriel bâti sur la science et l'innovation. C'est cette ambition qui anime encore aujourd'hui la mission du Groupe : « Create the Beauty that Moves the World ». Présent dans 150 pays avec un portfolio de plus de 40 marques différentes, L'Oréal a enregistré une croissance de +4,0% de son chiffre d'affaires annuel atteignant 44,05 milliards d'euros en 2025 (L'Oréal, 2026) avec une marge d'exploitation de 20,2%. Les ventes en ligne représentent désormais plus de 30% des ventes totales.

Parmi les marques qui font partie de ce groupe, on retrouve quatre grandes divisions. Les gammes Grand Public représentent 37% du chiffre d'affaires : L'Oréal Paris (n°1 mondial de la beauté grand public), Garnier (fort engagement dans la durabilité avec des formules vegan et rechargeables), Maybelline New York et NYX Professional Makeup. Les gammes de Luxe comprennent Lancôme, Yves Saint Laurent Beauté, Giorgio Armani Beauty et Kiehl's. La beauté dermatologique, très répandue sur le marché, compte La Roche-Posay, CeraVe et Vichy et représente 16% du chiffre d'affaires. Enfin, les produits professionnels, comme Kérastase, représentent 12% du chiffre d'affaires.

Pour répondre à cette mission, l'entreprise investit énormément dans la Recherche et l'Innovation (R&I) pour développer des solutions cosmétiques durables, de haute qualité et de haute performance, avec un budget de plus de 1,3 milliard d'euros en 2025. Ce sont aujourd'hui 4 000 scientifiques répartis dans le monde, dont une partie au sein du centre CAPI et Chevilly en France, qui travaillent à développer des solutions cosmétiques de haute qualité et à impact environnemental réduit. On compte désormais 725 brevets déposés, dont 54% par des femmes couvrant des domaines tels que la Green Science, la BeautyTech et les formules durables.

L'Oréal compte plus de 95 000 collaborateurs dans le monde avec 37 usines et 160 centres de distribution répartis partout dans le monde : l'Europe représente 34% du chiffre d'affaires, suivie de l'Amérique du Nord (27%), de l'Asie du Nord : Chine, Japon et Corée (23%), de la zone SAPMENA-SSA (Asie du Sud, Pacifique, Moyen-Orient, Afrique) avec 9% et de l'Amérique Latine (7%).


Aujourd'hui, L'Oréal touche déjà environ 1,5 milliard de consommateurs à travers ses marchés émergents et établis, avec l'ambition de conquérir 500 millions de nouveaux consommateurs d'ici 2030, notamment portée par l'essor de l'Inde et des classes moyennes émergentes. Face à ce changement d'échelle historique, l'intégration de la technologie et de l'analyse de données devient plus que jamais un impératif stratégique.


Pour décoder, anticiper et servir les besoins d'un volume aussi massif et diversifié de nouveaux consommateurs, c'est sans doute dans cette perspective que l'alliance entre la technologie et la science cosmétique s'annoncera plus que jamais essentielle.

Problématique

Mon stage prend place dans un contexte d'Innovation en pleine expansion, au sein duquel L'Oréal conduit depuis plusieurs années un grand programme de Transformation Digitale. Dans cette dynamique, le recours à l'Intelligence Artificielle comme outil d'accélération des processus de recherche et d'innovation occupe une place croissante et stratégique. Dans le domaine de la Formulation, les mesures de caractérisations Physico-Chimiques et de Performances des formules créées par les laboratoires génèrent des volumes très importants de données qu'il s'agisse de données de composition, de paramètres de procédés, de caractérisations ou de performances observées ou mesurées. Il est important de pouvoir capitaliser sur ces résultats et d'orienter les Formulateurs dans leurs travaux de reformulation (art de composer des produits cosmétiques) grâce à ces informations. Une formulation et ses Performances reposent sur des interactions physico-chimiques complexes entre les ingrédients qui la compose et sur les paramètres des procédés de sa fabrication. La formulation est donc un terrain particulièrement pertinent, mais également exigeant, pour l'apprentissage automatique.

Le projet nommé Predictivity est un projet résultant d'un partenariat de 3 ans signé entre la R&I L'Oréal et IBM Research afin d'accélérer la recherche sur les algorithmes pour répondre aux enjeux des laboratoires de la R&I, en utilisant l'Intelligence Artificielle (IA) via un Formulation Foundation Model (FFM). Son nom reflète cette double dimension : la formulation, qui constitue un métier central chez L'Oréal, et le modèle de fondation, qui désigne un type de modèle généralisable capable d'apprendre à partir de grands volumes de données qui est particulièrement adapté au contexte des grandes entreprises.





Parmi les données d'entrée possibles pour un modèle de fondation généraliste, on trouve les textes, les images, ou encore les données tabulaires. C'est d'ailleurs sur les textes que reposent les LLMs (Large Language Models), les modèles de fondation les plus connus du grand public. Dans le contexte de Predictivity, ce sont les données structurées qui se situent au cœur de ma mission. À partir de ces données, le modèle peut se spécialiser pour accomplir des tâches variées en entraînant le modèle : extraction d'informations, questions-réponses, etc. Il est important de préciser que

l'entraînement du modèle ne fait pas partie du périmètre de mon stage.

Le projet, auquel je contribue, ne se limite pas à une simple étude de faisabilité, mais s'inscrit dans une démarche d'implémentation concrète d'un modèle de fondation capable d'apprendre à partir de centaines de milliers de formules accumulées au fil des décennies. À terme, ce modèle a vocation à ne pas seulement suggérer de nouvelles formules en s'appuyant sur les connaissances issues des données historiques, mais aussi de prédire les performances de ces formules.

L'un des objectifs principaux de ce projet est de tirer parti des données historiques pour limiter les tâtonnements. En pratique, les Formulateurs s'appuient rarement sur une page blanche : ils partent d'une Formule existante et cherchent à l'améliorer. Cette démarche, appelée Reformulation, consiste à analyser les formules développées antérieurement afin d'en extraire les enseignements utiles. Elle peut prendre différentes formes : remplacer une matière première par une autre, faire évoluer la composition pour améliorer les performances sur un critère donné, ou encore répondre à des exigences plus spécifiques, telles que la réduction de l'impact environnemental.

Toute approche d'apprentissage automatique converge inévitablement vers la question fondamentale des données. Il apparaît dès lors impératif de garantir leur qualité, leur pertinence au regard des cas d'usage envisagés, ainsi que leur représentativité. C'est dans cette perspective que s'inscrit ma mission au sein de l'équipe Data, dont l'objectif est de contribuer à la gouvernance et la qualité des données destinées à être ingérées par le modèle de fondation.

1. Cadre industriel, scientifique et technique du stage

1.1 Positionnement du stage au sein de l'équipe Data

La qualité des données, qu'il s'agisse de sa remédiation, qui agit sur la donnée elle-même en corrigeant ses anomalies et incohérences, ou de la gouvernance, qui agit autour de la donnée en définissant les règles d'accès, les responsabilités et les processus encadrant sa gestion dans le temps, est un domaine dont la criticité n'a cessé de croître avec la massification de la production de données. Cette importance est aujourd'hui reconnue par l'ensemble des parties prenantes, des équipes techniques aux utilisateurs finaux.


Son impact se manifeste en amont, avant même que le produit final ne soit visible, ce qui en fait un levier souvent discret, mais déterminant. Pourtant, cette activité est l'une des plus critiques d'un projet fondé sur l'exploitation de données massives. En science des données, il existe un principe simple : un modèle ne peut pas être meilleur que les données qu'on lui donne (Sambasivan, 2021). C'est le principe du "Garbage In, Garbage Out" ; de mauvaises données en entrée produisent inévitablement de mauvais résultats en sortie (Wand, 1996). Gouverner la donnée, c'est donc identifier précisément, via des études préalables, quelles parties des données sont affiliées à quelles règles métiers, valider leurs cohérences et s'assurer de leurs pertinences pour le cas d'usage. C'est également garantir l'ensemble du cycle de vie de la donnée, définir les rôles et responsabilités de ceux qui interviennent sur celle-ci, et encadrer les droits d'accès qui lui sont associés.

C'est à ce carrefour entre architecture et traitement des données, analyse et gouvernance, au sein d'un écosystème structuré réunissant Data Stewards, Data Quality Managers et Data Engineers aux rôles clairement définis, que s'inscrit ma contribution au projet. J'ai occupé une position transversale, intervenant à plusieurs niveaux de l'architecture de données : en participant à des travaux de pipeline de données, en conduisant des analyses ciblées sur les données de formulation en vue de leur remédiation, et en contribuant à la synchronisation des règles métier entre le périmètre du projet Predictivity et le référentiel de gouvernance global de la R&I chez L'Oréal. Ces trois dimensions sont détaillées dans les sections qui suivent.


1.2 Positionnement technique

Afin de garantir que chaque donnée produite, collectée ou stockée au sein de nos équipes soit nommée, classifiée et structurée de manière cohérente dès sa génération,

L'Oréal R&I a mis en place depuis plus de 5 ans un cadre clair, partagé et gouverné de façon à savoir où trouver une donnée, comment l'interpréter, et s'assurer qu'elle est comparable d'un contexte à l'autre. Une Taxonomie des données de la R&I a notamment été mise en place. Il s'agit d'un système de classification hiérarchique qui structure les données en catégories cohérentes, avec des conventions de nommage standardisées, garantissant que chaque donnée est identifiable et exploitable de manière uniforme par l'ensemble des parties prenantes.




Chez L'Oréal, cette Taxonomie est formalisée selon une hiérarchie à cinq niveaux. Au sommet se trouvent les domaines qui constituent les ensembles les plus larges de données. Ils couvrent des périmètres fonctionnels distincts tels que la Recherche & Innovation, le Juridique, la Supply Chain ou encore le Sourcing. Au sein de chaque domaine se trouvent des familles de données. Dans le domaine R&I par exemple, on a la famille Formula qui contient des données pivots pour le FFM et cette famille se décompose ensuite en sous-familles (Formula Characteristics ou Sales), assimilables à des schémas au sens relationnel du terme. Ces sous-familles contiennent des Business Objects (Composition par exemple), qui correspondent aux tables d'une



base de données relationnelle. Enfin, au niveau le plus granulaire, les Business Object Attributes, (BOA), désignent les variables de ces tables, soit les colonnes qui décrivent chaque entrée.

Le Shared Domain Dataset (SDDS), est le système au sein duquel la Taxonomie l'Oréal prend forme concrètement dans l'environnement Google Cloud Plateforme (GCP) pour stocker physiquement les données. Il se présente sous forme de vues, c'est-à-dire des représentations structurées des données organisées selon la hiérarchie décrite précédemment, depuis les Domaines jusqu'aux Business Object Attributes.

Un LLM impose des exigences strictes quant au format et à la structure des données qui lui sont soumises pour l'entraînement. L'architecture médaillon, modèle de structuration des données prépondérant en Ingénierie des données, s'impose alors comme la solution la plus adaptée qui permet d'adresser progressivement ces exigences.




Dans sa forme canonique, elle repose sur trois couches successives aux rôles distincts impliquant des séries de transformation de données. La couche Bronze assure l'harmonisation et la mise en commun des données issues des différents SDDS. La couche Silver est dédiée à l'application des règles de qualité des données et à la préparation en terme de Structuration des données aux besoins du LLM. Enfin, la couche Gold assure l'exposition des données au modèle de fondation dans un état normalisé et exploitable. Dans le cadre du projet Predictivity, cette architecture a été adoptée et elle a été adaptée avec une terminologie singulière, propre aux spécificités du projet.

La couche la plus amont, et par conséquent la plus brute, est l'entrepôt de données (Data Warehouse). Les données n'y arrivent pas directement depuis les laboratoires sans traitement : un mapping complexe est réalisé entre l'entrepôt de données et le système source d'acquisition des données de caractérisation des formules par exemple. Ensuite entre les entrepôts de données et les SDDS un mapping est réalisé respectant la Taxonomie définie.

Les données de caractérisations des formules sont issues d'expérimentations utilisant des appareils et logiciels de mesures. En exemple de caractérisation est la Rhéologie qui désigne la science de l'étude de l'écoulement et de la déformation de la matière sous l'effet de contraintes mécaniques. Il existe d'autres caractérisations comme la

Colorimétrie, ainsi que les Evaluations Sensorielles par exemple de texture et de tenue de la formule sur un support. Les données issues des appareils sont ensuite transmises à des systèmes d'information, ou sont saisies directement par les Formulateurs dans ces mêmes systèmes. Une fois structurées et converties en données relationnelles respectant les Taxonomies, elles permettent la construction de schémas de bases de données destinés à alimenter les couches supérieures de l'architecture.



Dans la nomenclature propre au projet Predictivity, les couches Bronze et Silver sont toutes deux désignées sous le terme de CDS, pour Consumption Dataset. Bien qu'elles constituent deux schémas distincts, elles partagent la même dénomination. La couche Gold, quant à elle, conserve sa dénomination canonique. Le détail de leur implémentation technique dépasse le périmètre de ce stage, mais en comprendre la logique globale reste nécessaire pour appréhender le travail effectué. Ce qui importe ici, c'est que l'ensemble de ce processus intermédiaire vise à décomposer méthodiquement les problématiques liées à la qualité des données. Ces problématiques ne se limitent pas à des erreurs de « validité de la donnée », elles englobent également des problèmes de labélisations ou de structuration des données face aux exigences du modèle. À l'issue de ce processus de transformation et d'enrichissement progressif, la couche Gold contient des données suffisamment fiables et normalisées pour répondre à l'usage cible, à savoir dans le cadre de Predictivity, l'entraînement du FFM.

À chaque transition entre deux couches, des opérations de transformations sont réalisées : entre le SDDS et la couche Bronze du CDS, des filtres de sélection et un processus de modélisation de données sont appliqués afin de structurer la donnée brute. C'est ensuite au niveau de la couche Silver que des contrôles de qualité sont effectués et la structuration en vue de l'adaptation des données aux attentes du FFM sont effectuées. Dans la couche Silver, des tags sont apposés sur les données ne respectant pas les règles de qualité définies, elles permettent de tracer et d'identifier les anomalies avant toute exploitation. Ces tags constituent également la base d'un suivi analytique : grâce à un Dashboard Power BI, il est possible de mesurer et de visualiser le volume de données ne respectant pas les règles de qualité. Dans ce dispositif, mon rôle de gouvernance des données se concentre essentiellement sur la couche Silver, là où les règles de qualité sont appliquées.

Ces règles de qualité des données permettent la détection des données non conformes de façon automatique et systématique. Elles constituent donc le point de départ indispensable de tout effort de nettoyage structuré. Les sections suivantes illustreront comment cette approche permet de produire des analyses concrètes, de les soumettre aux experts métier pour validation, et d'engager ensuite un processus de remédiation ciblé.

1.3 Brève introduction aux missions du stage

1.3.1 Règles métiers, un levier pour la gouvernance et remédiation de données

Nous avons mis en place la création de règle métiers, ou Business Rules à appliquer aux données afin d'en évaluer la qualité. Ces règles constituent en quelque sorte un code de la route pour la validation des données : elles documentent des conditions logiques, des directives et des contraintes qui permettent d'évaluer de manière ciblée et systématique si une donnée est utilisable, pertinente, valide et complète. Dans le cadre de Predictivity, l'exemple le plus simple est celui du pH :

SI l'attribut est pH **ALORS** la valeur doit être comprise entre 0 et 14

Le pH mesure l'acidité ou l'alcalinité d'une solution sur une échelle allant de 0 à 14, un paramètre critique en formulation cosmétique dans la mesure où il conditionne directement la compatibilité du produit avec la peau et sa stabilité. Or, lorsqu'une valeur de pH supérieure à 14 est détectée dans les données, elle ne peut pas correspondre à une mesure physiquement valide. Elle signale alors très vraisemblablement une anomalie dans la chaîne de traitement de la donnée : une saisie erronée dans un logiciel de laboratoire, une modification intervenue à une étape du processus, ou encore une corruption survenue lors du transfert des données, dont l'origine exacte n'est pas toujours identifiable avec certitude.

Ces règles sont définies collectivement lors de workshops appelés Analyse Exploratoire des Données (EDA) avec les experts métiers et ingénieurs des données. Elles sont centralisées dans un logiciel dédié : le Référentiel Recipe Data Dictionary, affectueusement baptisé R2D2, en référence au célèbre robot astromécano de la saga Star Wars. R2D2 est une PowerApp développée en interne, qui regroupe et structure l'ensemble des règles métiers définies lors des EDAs.

Avant mon arrivée, l'équipe avait fait face à une contrainte de temps et pour formaliser rapidement les Règles métiers identifiées dans le cadre du projet Predictivity, et avait eu recours à un Excel comme support de travail permettant de décrire et documenter les

règles implémentées dans la couche Silver. Son utilisation parallèle à R2D2 a nécessité de regrouper dans R2D2 des règles identifiées dans cet Excel et avant cela d'effectuer un « Gap Analysis » : analyse d'écart de règles métiers entre ces deux supports afin de ne pas déclarer dans R2D2 des règles métiers déjà existantes.

Par ailleurs, dans le cadre de Predictivity des règles métiers spécifiques au cas d'usage du FFM ont été identifiées et il est nécessaire de les déclarer dans R2D2 comme telles afin qu'elles ne soient pas appliquées à l'ensemble des données de la R&I. La cohérence des règles métiers avec leur usage est primordiale à tracer.

1.3.2 Analyse et remédiations des données

Une formule est composée d'une liste d'ingrédients, de leurs proportions et des paramètres de procédé associés. C'est cette combinaison qui définit entièrement la Formule. Ensuite chaque Formule est associée à des données de caractérisation, telles que les mesures Physico-Chimiques, les Performances observées. La qualité de ces données conditionne directement la fiabilité des suggestions produites par le modèle et leur exploitabilité par les formulateurs.

Pour évaluer l'état de ces données, nous avons choisi de nous concentrer sur un ensemble d'attributs liés aux caractérisations des formules. L'idée était simple : vérifier non pas seulement si chaque attribut pris individuellement était valide, mais si l'ensemble de ces attributs racontaient une histoire cohérente. Car un ensemble de valeurs peuvent sembler correctes séparément et se contredire mutuellement lorsqu'on les met en relation.

Dans ce cas précis, le travail s'articule autour de trois BOA qui racontent une histoire autour du pH, c'est-à-dire le taux d'acidité d'une formule : Mesurable pH, indiquant si le pH est mesurable, autrement dit si l'on peut effectuer une mesure à partir d'une formule spécifique à l'aide d'un appareil dédié ; pH, qui correspond à la valeur de pH elle-même ; et Standard Deviation, qui décrit l'imprécision de l'outil lors de la mesure du pH.

Ce principe de cohérence entre attributs ne se limite pas au pH, il s'applique à tout type de données et la démarche est reproductible sur n'importe quel ensemble d'attributs au sein de l'architecture.

1.3.3 L'Industrialisation de flux de données

Chez L'Oréal, certains projets font appel à des prestataires externes pour leur développement, et Predictivity ne fait pas exception. Ce mode de fonctionnement, bien que courant, soulève une question structurelle : comment garantir la continuité et la maintenabilité d'un projet après le départ des équipes qui l'ont construit ? La réponse réside dans la qualité de sa documentation. C'est précisément ce que l'on désigne ici par

industrialisation : transformer un projet en développement en un système pérenne, compréhensible et exploitable de manière autonome, sans dépendre de la mémoire de ceux qui l'ont conçu.

Au fil du projet, un volume considérable de code a été produit et réparti sur les différentes couches de l'architecture médaillon, du SDDS jusqu'à la couche Gold. Chaque couche embarque ses propres transformations, ses propres logiques de filtrage et de validation, ce qui engendre une complexité croissante difficile à appréhender sans un fil conducteur clair. Dans ce contexte, il est devenu indispensable d'assurer une traçabilité des attributs tout au long de ce parcours, afin de pouvoir répondre à une question en apparence simple mais techniquement exigeante : d'où provient un attribut donné, et par quelles transformations est-il passé à travers les différentes couches pour atteindre son état final ?

Ma contribution a consisté à documenter le flux de données entre le SDDS et la couche Bronze du CDS. Pour ce faire, j'ai analysé un ensemble de fichiers SQL définissant les pipelines de transformation. Chaque fichier porte le nom de la table Bronze qu'il alimente : dans l'exemple détaillé dans les sections suivantes.

2. Mise en œuvre technique des travaux réalisés

2.1 Analyse, qualification et synchronisation des règles métiers

2.1.1 Analyse du référentiel existant

La première mission entreprise à la prise de poste a été l'analyse d'un fichier Excel centralisant les règles métier spécifiques au projet Predictivity (au nombre de 322), plus précisément désignées sous le terme de Predictivity Use Cases. Un identifiant unique à chaque règle s'y trouve. À titre d'exemple, le cas d'usage portant sur la mesure numérique du pH se voit attribuer l'identifiant `measurement_numeric-0068`.

Dans un second fichier, désigné ici comme fichier B, sur trouvent les règles métiers issues d'un export des règles physiquement implémentées dans le Silver. L'objectif de mon travail était d'identifier si les règles métiers du fichier A listaient bien toutes les règles présentes dans le fichier B.

Le processus de réconciliation a révélé une difficulté majeure : aucune colonne ne pouvait servir de clé pivot fiable entre les deux fichiers. Si certains champs présentaient des similarités structurelles, aucun attribut n'était suffisamment cohérent entre les deux sources pour permettre une jointure directe.

Une première approche a consisté à automatiser l'appariement en recourant à la similarité cosinus, appliquée à l'attribut jugé le plus représentatif sur le plan sémantique

: la Rule Description, qui fournit une description en langage naturel de chaque cas d'usage. Le champ correspondant dans le fichier B est intitulé Old Description.

$$\text{similarity}(\mathbf{A}, \mathbf{B}) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \cdot \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \cdot \sqrt{\sum_{i=1}^n B_i^2}}$$

Cette méthode repose sur une représentation vectorielle des descriptions textuelles : chaque description est encodée sous la forme d'un vecteur dense par un modèle de type sentence transformer, qui capture le sens global de la phrase en tenant compte du contexte sémantique de chaque mot (Reimers, 2019). Ces modèles, fondés sur une architecture transformer pré-entraînée, sont capables de saisir des relations sémantiques fines entre les termes, allant bien au-delà d'une simple comparaison lexicale. La similarité cosinus est ensuite calculée entre les vecteurs de deux descriptions produisant un coefficient compris entre 0 et 1, où 1 traduit une correspondance sémantique exacte et 0 une absence totale de similarité. La méthode a été implémentée en Python de la manière suivante :


```

SIMILARITY_THRESHOLD = 0.65

print("\nLoading semantic model (first run will download it)
...")
model = SentenceTransformer('all-MiniLM-L6-v2')

def semantic_match(df1_values, df2_values, label, threshold):
    :
    print(f"\nSemantic matching: {label}")

    df1_embeddings = model.encode(df1_values,
convert_to_tensor=True)
    df2_embeddings = model.encode(df2_values,
convert_to_tensor=True)

    match_map = {}
    score_map = {}
    matched = []
    unmatched = []

    for i, val in enumerate(df1_values):
        scores = util.cos_sim(df1_embeddings[i],
df2_embeddings) [0]
        best_idx = scores.argmax().item()
        best_score = scores[best_idx].item()
        best_match = df2_values[best_idx]

        if best_score >= threshold:
            match_map[val] = best_match
            score_map[val] = round(best_score, 4)
            matched.append((val, best_match, best_score))
        else:
            unmatched.append((val, best_match, best_score))

```

Les résultats de cette approche se sont révélés limités : seules une soixantaine de règles ont pu être appariées avec succès entre les deux fichiers, représentant moins d'un cinquième du nombre total. Les entrées restantes ont dû faire l'objet d'une réconciliation manuelle.

2.1.2 Comparaison avec les éléments documentés dans R2D2

L'identification des règles métiers implémentées dans le Silver décrite dans le paragraphe précédent m'a permis d'alimenter R2D2 avec de nouvelles règles métiers.

Avant d'aborder celle-ci, il est nécessaire de comprendre le fonctionnement de R2D2.

R2D2 centralise les règles métiers, classées selon la Taxonomie (c'est-à-dire la famille, la sous-famille, le BO et le BOA). Il contient également le périmètre auquel s'appliquent les règles métiers ainsi que la dimension des règles (Complétude, Unicité, Validité, Actualisation, Cohérence, Exactitude). Chaque règle dispose d'une description et d'un statut : validée, obsolète, à valider, ou sans objet (N/A).

Avant d'ajouter toute règles métiers dans R2D2, il faut vérifier si celle-ci y existe déjà afin d'éviter tout doublon et aussi si cette règle métier s'applique uniquement au cas d'usage de Predictivity ou bien est générale aux données de la R&I.

2 lots distincts de règles métiers ont été définis.

Le premier lot, plus simple, porte sur les tables descriptives (BO) correspondant aux Informations Générales des Formules (FGI), les informations générales de matière première (RMG), les caractéristiques de Formule (FLA) et les caractéristiques de matière première (RMC). Pour chaque règle métier, il a été nécessaire d'identifier les attributs (BOA) auxquels elle s'applique et rédiger la requête SQL correspondante afin que l'équipe chargée de l'injection des nouvelles règles dans R2D2 puisse lancer les opérations d'enrichissement.

Si l'identification des attributs correspondants s'avère relativement aisée, la traduction du code SQL demande nettement plus de temps. En effet, le code SQL d'origine est écrit sous forme de sproc (N.T. : procédure stockée permettant d'automatiser l'exécution de requêtes SQL), dont le code ne peut pas être directement réutilisé. Pour illustrer ce problème, voici le cas de la règle métier formula_metadata_numeric-0029.

```
name != "green_chemistry_raw_material_excl_water_percentage"
OR (
  name = "
    green_chemistry_raw_material_excl_water_percentage"
  AND (
    value >= 0
    AND value <= 100
  )
)
```

La traduction exige de supprimer les variables name et value, et d'appliquer directement la condition sur la valeur de l'attribut concerné : name correspond au nom de l'attribut et value à la valeur que cet attribut peut prendre. La traduction se présente alors sous la forme suivante.

```
green_chemistry_raw_material_excl_water_percentage >= 0  
AND green_chemistry_raw_material_excl_water_percentage <=  
100
```

Il s'agit bien entendu de l'exemple le plus simple de la liste. Les cas plus complexes peuvent impliquer plusieurs attributs et plusieurs valeurs, et il est indispensable de vérifier la conformité des types de données afin de s'assurer que le code SQL traduit soit exécutable.

Le premier lot s'est avéré relativement simple car il ne concerne pas des BOA ayant subis des transformations dans la couche silver, ainsi le data lineage pour construire la requête SQL de la règle métier est direct.

Le deuxième lot est plus complexe car dans la couche Bronze un data modèle spécifique a été créé afin de regrouper une dizaine de SDDS de structuration différente dans un seul et même data modèle afin de simplifier les travaux dans la couche Silver. Le data lineage entre BOA n'est donc plus direct et les requêtes SQL pour définir les règles métiers sont donc complexes à réaliser.

Compte tenu de cette complexité, la progression sur le second lot nécessite une compréhension approfondie et demandant du temps d'approfondissement. Ma mission a ainsi été réorientée vers un nouveau périmètre de contribution plus technique, détaillé en section 2.3.

2.1.3 Vérification de distinction entre Business Rule et Predictivity Use Case

Afin de vérifier si une règle métiers identifiée dans le cadre des EDAs de Predictivity est spécifique à ce cas d'usage ou bien est généralisable à la R&I, j'ai travaillé avec les Data Stewards ayant l'ownership sur ces données.

Ce processus implique de nombreux allers-retours, notamment par l'organisation de réunions. Cette partie du travail mobilise moins d'expertise technique qu'elle ne requiert d'importantes capacités relationnelles. Les Data Stewards exercent des responsabilités multiples et le rôle de Data Steward n'est qu'une partie de leur mission, il faut donc lors des réunions avec eux leur présenter une synthèse claire des règles métiers et obtenir leur validation sur spécificité ou pas des règles métiers.

Pour faciliter ce suivi, un système de gestion léger a été mis en place : un fichier centralisant la liste des Data Stewards et leurs fichiers associés, chacun contenant N règles métiers rattachées. Ce fichier permet de suivre les messages envoyés, d'identifier si un atelier de travail est nécessaire, et surtout de vérifier si le fichier source des cas d'usage Predictivity a bien été mis à jour avec les étiquettes correspondantes (règle métier ou cas d'usage Predictivity).

2.2 Remédiation des données de formule

Tandis que la section précédente traite de la mise en œuvre et de la résolution d'une hétérogénéité des données pour les règles métiers, la présente section correspond à ce que je considère personnellement comme la partie la plus intéressante de ma mission. Bien qu'elle ait été conduite en parallèle d'autres missions, elle illustre de façon concrète comment analyser et remédier la qualité des données dans un contexte professionnel.

2.2.1 Analyse préliminaire

Comme mentionné en introduction, l'analyse s'appuie sur trois attributs principaux relatifs au pH : mesurable pH code, pH et standard deviation pH. Le Business Object associé à ces attributs est `flc_formula_ph`, localisé dans le BO « Formula Master Data Characteristics » et dans le SDDS FGI (Formula General Information).

Il existe des centaines de milliers de Formules dans le SDDS Formula et donc à chaque fois des caractérisations Physico-Chimiques associées et un exemple de celle-ci est le pH de la formule.

J'ai combiné les valeurs que peuvent prendre les BOAs mesurable pH, pH et standard deviation pH pour identifier les différentes combinaisons de valeurs existantes.

- Mesurable pH code peut prendre les valeurs OUI ou NON au format STRING, ou être NULL.
- Les attributs pH et standard deviation peuvent quant à eux contenir une valeur (NOT NULL) sous forme d'entier, ou être NULL.


En listant l'ensemble des combinaisons, il est alors possible de déduire les actions à entreprendre pour chaque sous-cas et de précalculer la volumétrie associée (cf. Annexe I).

Mon objectif a été de fournir au Data Steward les informations nécessaires afin qu'il puisse pour chaque sous-cas définir des règles de remédiation c'est-à-dire de corrections (dans un cadre bien borné et définit). Nous pourrions ainsi augmenter le nombre de pH de Formules pris en comptes dans l'entraînement du modèle jusqu'alors filtrées suite à l'application des règles métiers.

Par ex. le cas où le mesurable pH vaut NON ou NULL, et où la valeur de pH est non nulle (NOT NULL). En corrigeant mesurable pH à OUI, à condition de respecter des conditions bien précises, il devient possible de réutiliser la valeur de pH déjà renseignée.

Comme indiqué dans le tableau en Annexe I, une première EDA conduite avant mon arrivée a conclu que les formules dont la concentration totale en eau est supérieure à 60 % sont les plus susceptibles de pouvoir être remédiées avec la règle décrite ci-dessus (pH renseigné et mesurable pH non renseigné ou valant NON).

D'autres critères ont été ajoutés en plus de la concentration en eau afin d'aider le Data Steward dans son analyse, tels que la date de création et le laboratoire de production, comme illustré dans la figure ci-dessous pour le cas 1, où 173 formules ont été identifiées.



Concernant le BOA standard deviation, il est fixé à 0.3 par défaut car il s'agit de la valeur théorique fournie par l'appareil de mesure du pH. Une voie de remédiation serait donc de remplacer les NULL en mesurable pH par 0.3 dans le cas où un pH est renseigné. Là encore il faut bien vérifier les volumétries la cohérence des informations relatives aux formules concernées par ce sous cas.

A l'issu de cet exercice nous avons eu une première vision sur les volumétries concernées pour chacun des cas.

2.2.3 Méthodologie de correction

Afin que le Data Steward puisse faire l'analyse des données concernées par chacun des cas, je lui ai donné accès en consultation à ces données.

Le Data Steward, après l'étude des données, a demandé des informations complémentaires sur les formules concernées pour compléter son analyse et définir les cas où les remédiations seraient possibles :

- La valeur du lot de fabrication de la formule
- La norme de la formule, généralement exprimée sous la forme $\text{pH} \pm \text{écart-type}$. C'est la valeur de contrôle (spécification) attendue lors des productions en usine
- Le statut de la formule (cycle de vie de la formule).
- Le drapeau d'activité de la formule (formula active flag) : indique si la formule est active ou non.

- Le nom du métier : le métier auquel la formule est associée, selon les catégories propres à L'Oréal (par ex. Hair Care).
- Le nom du laboratoire : le laboratoire dans lequel la formule a été développée (par ex. development).
- Formule en développement ouvert (open dev formula) : indique si la formule est fabriquée par une autre entreprise que l'Oréal, sous la forme d'un booléen vrai/faux.
- L'état de la formule : sa forme physique (liquide, aérosol, solide).

Les formules étant composées de différentes matières premières, il est pertinent pour l'expert de vérifier si certaines matières premières aux rôles fonctionnels significatifs sont présentes. Les critères retenus sont les suivants :

- Un agent régulateur de texture minéral : présence détectée à partir d'un seuil de concentration défini.
- Un agent osmotique et stabilisant : présence détectée à partir d'un seuil de concentration défini.
- Un agent alcalinisant : composé capable d'augmenter le pH et l'alcalinité de la formule, identifié parmi un ensemble de matières premières référencées à cet effet.
- Un agent acidifiant : acide organique naturel faible, utilisé pour ajuster le pH vers des valeurs acides, identifié parmi un ensemble de matières premières référencées.
- Un agent gélifiant : polymère naturel ou synthétique capable d'absorber l'eau et de former un réseau tridimensionnel, conférant à la formule une texture gel et une viscosité élevée, identifié parmi un ensemble de matières premières référencées.

L'analyse comprend également plusieurs indicateurs complémentaires :

- Le solvant alcoolique : sa concentration est extraite afin d'évaluer son influence sur la stabilité, la texture et la sensation à l'application du produit fini.
- Le solvant glycolique : sa concentration permet d'apprécier le pouvoir hydratant de la formule et sa capacité à maintenir une texture stable.
- La concentration totale en tensioactif inverse : sa concentration est isolée pour évaluer l'effet adoucissant et conditionnant de la formule sur le substrat cible.
- La concentration totale en tensioactif : somme de l'ensemble des agents de surface présents dans la formule, accompagnée du nom des ingrédients associés, afin d'évaluer le pouvoir détergent et moussant global.
- La somme des concentrations en solvant alcoolique, eau et solvant glycolique : indicateur global de la phase aqueuse et des co-solvants, reflétant la balance hydrophile de la formule.

- La somme de matières premières : Cela permet de vérifier que la concentration totale de l'ensemble des matières premières de la formule est bien égale à 100 %.

Cf. Annexe II pour l'implémentation SQL complète.

2.2.4 Résultats obtenus sur les jeux de données traités

Les résultats obtenus à la date de soumission du rapport témoignent d'un taux de remédiation cible globalement élevé pour l'ensemble des sous-cas traités.

Sous-cas	Conditions de filtrage			Formules identifiées	Formules corrigées	Taux (%)
	measurable_ph_code	ph	standard_deviation_ph			
1	NON	NOT NULL	NOT NULL	173	160	92.5
2	NON	NOT NULL	NULL	48	48	100.0
3	NULL	NOT NULL	NULL	5 968	5 387	90.3
4	NULL	NOT NULL	NOT NULL	50 497	49 299	97.6

Le sous-cas 1 affiche un taux de correction de 92,5 % : 160 formules corrigées sur 173. Parmi elles, 134 voient leur measurable_ph_code passer à OUI ; les 39 formules restantes conservent un measurable_ph_code à NON, avec les valeurs de ph et standard_deviation_ph remises à NULL.

Le sous-cas 2 atteint un taux de correction de 100 % sur 48 formules. Pour 42 d'entre elles, le measurable_ph_code est changé à OUI et une valeur par défaut de 0,3 est renseignée pour le standard_deviation — valeur par défaut de l'appareil de mesure. Les 6 formules restantes ont leurs valeurs de ph et standard_deviation remises à NULL.

Le sous-cas 3 atteint un taux de 90,3 % avec 5 387 formules remédiées sur 5 968, ce qui en fait le sous-cas présentant la marge résiduelle la plus importante en proportion. Ces 5 387 formules sont remises à OUI avec la valeur par défaut de 0,3 pour le standard_deviation.

Le sous-cas 4 est de loin le plus volumineux, avec 50 497 formules identifiées. Il affiche un taux de remédiation de 97,6 %, soit 49 299 formules effectivement corrigées, et constitue la contribution principale en volume absolu. Parmi elles, 49 285 ont leur measurable_ph_code passé à OUI, et 14 ont leur measurable_ph_code passé à NON avec les valeurs de ph et standard_deviation remises à NULL.

Au total, ces résultats confirment que par notre approche nous allons pouvoir corriger la qualité de données au niveau de cette caractérisation de façon conséquente en termes de volumétrie et ainsi ajouter de nombreuses données pour le FFM. Les cas pour lesquels la validation par l'expert métier n'a pas permis de conclure avec suffisamment

de certitude à une erreur ou manque de saisie, ont donc été écartées par précaution afin de ne pas introduire de biais dans les données d'entraînement.

2.3 Industrialisation de flux de données

2.3.1 Périmètre de la cartographie et choix méthodologique

La première tâche liée à l'industrialisation du flux de données a consisté à documenter 5 tables différentes de la couche CDS Bronze, entièrement écrites en SQL. Ces tables sont: `rpm_operating_parameter`, `rpm_result`, `rpm_sample`, `rpm_study` et `rpm_test`.

J'ai réalisé des spécifications sur le flux de données entre le SDDS et la couche Bronze du CDS. Pour ce faire, j'ai travaillé avec un ensemble de fichiers SQL définissant les pipelines de transformation. Chaque fichier porte le nom de la table Bronze qu'il alimente.

Ce qui frappe d'emblée lorsqu'on parcourt ces fichiers, c'est la progression quasi-continue de leur complexité. Les premières tables, telles que `rpm_result` ou `rpm_sample`, constituent des cas relativement simples : quelques dizaines de lignes de code, une source SDDS unique, des transformations limitées. Elles offrent un bon point d'entrée pour comprendre la logique de mapping et la structure du référentiel de correspondance.

Mais à mesure que l'on avance dans le périmètre, la complexité s'accroît de façon significative. La table `tdm_sub_results` représente déjà un saut qualitatif important, avec plusieurs centaines de lignes de code, l'introduction de multiples CTEs (Common Table Expressions). Les CTEs sont des sous-requêtes SQL temporaires permettant de structurer et de décomposer la logique d'une requête complexe en étapes lisibles et réutilisables, et d'agréger de sources SDDS hétérogènes. Elle constitue une étape intermédiaire qui prépare les données pour la table la plus ambitieuse du périmètre : la table `tdm_results`.

La table `tdm_results` contient plus d'un millier de lignes de code, elle n'agrège pas moins de 33 tables distinctes issues de 13 schémas SDDS différents. Avec cette table, nous rassemblons des données issues de plusieurs sous familles et familles différentes : Performance, Analyses, Caractérisation, Microbiologie et mobilise des dizaines de CTEs imbriquées. Les sections suivantes détaillent cette méthode, en illustrant d'abord la structure du référentiel de correspondance, puis en décrivant comment la traçabilité des attributs est assurée selon le niveau de complexité de chaque table.

2.3.2 Structure du référentiel de mapping SDDS → CDS

La table source à partir de laquelle les attributs sont extraits via SELECT provient d'une table unique localisée dans la couche SDDS. Cette table et ses attributs sont déterminants pour construire le mapping. À cet effet, un fichier de correspondance est utilisé, présentant à gauche la couche inférieure (SDDS) et à droite la couche supérieure (CDS), accompagnée de la Taxonomie associée. Les champs essentiels pour le CDS et le SDDS sont les suivants :

SDDS :

- Data Set
- Table/View
- Field
- Data Type
- Primary Key

CDS :

- Table/View
- CDS Field
- Data Type
- Primary Key
- Calculated GCP field (Yes/No)
- Detail Calculation
- Category (CTE, Condition, Output)
- Description

Ces champs sont relativement explicites. La subtilité réside dans le champ GCP calculé et le champ Détail du calcul : le premier indique s'il existe des transformations au niveau de l'attribut (changement de type, condition appliquée, etc.). Le second documente l'implémentation concrète de cette transformation.

Le champ Catégorie indique à quel usage cette partie du code est destinée. Par exemple, les attributs extraits directement dans la clause SELECT sont classifiés en tant qu'Output. Les attributs de la partie conditionnelle débutant par WHERE sont classés en tant que Condition. Enfin, les CTEs (Common Table Expressions — structures SQL intermédiaires permettant d'agréger des données réutilisables dans la sortie finale) sont des tables intermédiaires et constituent la catégorie CTE. L'indication de nom de CTE est documentée dans la Description

2.3.3 Analyse des chaînes de transformation SQL et traçabilité de la lignée des attributs

```
SELECT DISTINCT
    s.tested_sample_ms_id,
FROM 'itg-btdppublished-gbl-ww-pd.
    btdp_ds_c2_9ff_rm_pcp_eu_pd.rmp_tested_sample' s
s.ri_data_confidentiality = 0
```

Pour illustrer le mapping, un extrait du code issu de la table rmp_result est présenté. La requête SQL provient d'une source unique localisée dans la couche SDDS, sans CTE définie. Une seule condition est définie, impliquant l'attribut ri_data_confidentiality. La lignée de l'attribut se résume donc à une entrée unique dans le référentiel, reliant la source SDDS à la sortie CDS. Une deuxième entrée est insérée pour le même attribut, et la catégorie de condition correspondante est référencée en Annexe III. La section relative à la taxonomie a été exclue de cet extrait.

À l'opposé, tdm_results mobilise des dizaines de CTEs imbriquées sur plus d'un millier de lignes, ce qui accroît les exigences en matière de traçabilité. Certains attributs résultent de transformations effectuées au sein d'une CTE, telles que des concaténations, des agrégations ou des conversions de type, avant d'être exposés en sortie.

Un second extrait est présenté ci-dessous, impliquant un appel à la CTE results_iev au niveau de l'Output. Tel que présenté en Annexe III, les attributs présents dans la CTE sont documentés dans les deux premières lignes, où ils sont liés à result_id via une concaténation en sortie. Lorsqu'une transformation est impliquée, l'attribut est classifié comme calculé et la portion de code correspondante est renseignée.

```
with results_iev as
(SELECT DISTINCT
concat(study_design_code,"#",evaluation_output_code,"#
    AVERAGE") AS result_id,
average as result_value_numeric
FROM 'itg-btdppublished-gbl-ww-pd.
    btdp_ds_c2_9ea_instrumental_evaluation_eu_pd.
    iev_descriptive_statistics_v2' where
    evaluation_output_code is not null
and average is not null
```

```
SELECT DISTINCT
    result_id,
    result_value_numeric
FROM results_iev
```

Deux conditions sont présentes dans ce cas, impliquant `evaluation_output_code` et `average`. Lorsqu'un attribut fait office de condition, une entrée distincte est créée pour indiquer l'attribut dans la SDDS et la condition associée, sans renseigner l'entrée CDS. Le nom de la CTE est consigné dans le champ Description afin de faciliter l'identification de la CTE associée à un attribut donné.

Enfin, au niveau de l'Output, les deux attributs présents sont documentés et classifiés comme Output. Grâce à ce double niveau d'entrée, il est possible de reconstituer de manière récursive l'intégralité du chemin parcouru par n'importe quel attribut à travers les couches de l'architecture, en identifiant à chaque niveau les transformations associées, depuis sa source SDDS jusqu'à son état final en CDS.

3. Résultats, expérimentation et validation

3.1 Méthodologie d'évaluation

L'évaluation des travaux conduits au cours de ce stage repose sur une approche composite, adaptée à la nature hétérogène des trois axes de contribution. Chaque axe a fait l'objet d'une méthodologie d'appréciation distincte, combinant des indicateurs quantitatifs tels que le taux de couverture, la volumétrie de données corrigées et la complétude du référentiel, ainsi que des critères qualitatifs, notamment la validation par les experts métier et la conformité aux exigences de gouvernance définies par l'équipe data.

Pour l'axe règles métiers, l'évaluation s'est appuyée sur le suivi de l'état d'avancement de la réconciliation entre les deux fichiers sources et sur le taux d'injection des règles dans R2D2. Pour la remédiation des données de formule, le critère principal était le volume de formules effectivement remédiables par sous-cas, rapporté à la volumétrie initiale identifiée lors de l'analyse en section 2.2.1. Enfin, pour la cartographie des flux de données, la complétude du référentiel de mapping, c'est-à-dire le nombre d'attributs tracés de bout en bout entre le SDDS et la couche CDS Bronze, a constitué le principal indicateur de progression.

3.2 Critères de validation retenus

Les critères de validation ont été définis en cohérence avec les objectifs propres à chacun des trois axes. Pour la synchronisation des règles métiers, la validation repose sur deux conditions cumulatives : d'une part, la confirmation explicite par les Data Stewards responsables de la classification de chaque règle en tant que Business Rule générale ou Predictivity Use Case ; d'autre part, la mise à jour effective du fichier source avec les étiquettes correspondantes, condition préalable à toute injection dans R2D2. Une règle ne peut être considérée comme validée que lorsque ces deux étapes sont documentées dans le fichier de suivi décrit en section 2.1.3.

Pour la remédiation des données pH, la validation s'est opérée de manière itérative avec l'expert métier, selon le processus décrit en section 2.2.3. Chaque décision de correction a requis une revue manuelle du fichier extrait, fondée sur une combinaison de critères : concentration en eau supérieure à 60 %, statut et cycle de vie de la formule, présence de matières premières spécifiques. Pour la cartographie des flux, la complétude du mapping est évaluée attribut par attribut, en distinguant les sorties directes et les transformations intermédiaires passant par des CTEs, conformément à la structure du référentiel décrite en section 2.3.2.

3.3 Analyse critique des résultats

Axe 1 : Synchronisation des règles métiers. Sur les environ 322 cas d'usage Predictivity recensés dans le fichier source, seule une soixantaine a pu être appariée automatiquement par similarité cosinus, représentant moins d'un cinquième du volume total. Ce résultat, bien qu'en deçà des ambitions initiales d'automatisation, a permis de dégager un gain de temps réel sur la fraction la plus homogène du référentiel. Les entrées restantes ont nécessité une réconciliation manuelle.

Les travaux portant sur le Lot 1, composé des tables descriptives dont les Business Objects étaient déjà référencés dans R2D2, ont abouti à une progression satisfaisante. En revanche, concernant le Lot 2, impliquant le Transversal Data Model, le choix a été fait de réorienter mes efforts vers des tâches à dominante plus technique, laissant la poursuite de ces travaux aux équipes en place. J'ai donc ensuite travaillé sur le pipeline de données.

Axe 2 : Remédiation des données de formule Les résultats obtenus à la date de soumission du rapport témoignent d'un taux de remédiation globalement élevé. Sur un périmètre total de plus de 56 000 formules concernées, près de 55 000 ont pu être effectivement corrigées (dans le cadre de Predictivity dans un premier temps et sera appliqué au sein des données de la R&I dans un deuxième temps), représentant un taux de remédiation global d'environ 97 %.

Axe 3 : Industrialisation des flux de données. La cartographie des cinq tables CDS Bronze identifiées en section 2.3.1 a été réalisée, avec une complétude variable selon la complexité de chaque table. La table **rmp_result**, dont la requête SQL est directe et sans CTE, constitue un exemple de mapping abouti et documenté en Annexe III. À l'opposé, **tdm_results**, avec plus d'un millier de lignes de code et l'agrégation de 33 tables issues de SDDS distincts, représente le périmètre le plus complexe et celui dont la traçabilité complète a requis le plus d'effort analytique.

3.4 Limites des travaux réalisés et points de vigilance

Sur le plan méthodologique, l'absence de clé pivot fiable entre les fichiers sources de règles a contraint à recourir à une réconciliation manuelle pour la majorité des cas. Il est déconseillé d'utiliser un référentiel de règles métiers en dehors du système R&I car cela introduit une dette en termes de gouvernance de la donnée. Malgré tout, c'est ainsi que cela a été effectué pour avancer rapidement sur le projet et nous avons pu réconcilier les règles métiers en partie sur le lot 1 étudié.

Sur le plan organisationnel, l'implication des Data Stewards dans les cycles de validation, bien que nécessitant une coordination attentive compte tenu de leurs responsabilités multiples, constitue une garantie essentielle de la fiabilité et de la rigueur des règles métier validées. La mise en place d'un suivi formalisé, tel que le fichier centralisé décrit en section 2.1.3, renforce cette dynamique collaborative en fluidifiant les échanges et en assurant une traçabilité complète des décisions. Ces pratiques, consolidées au fil du stage, constituent des fondations solides sur lesquelles les équipes data pourront s'appuyer pour assurer la pérennité et la robustesse sur les sujets de qualité de données dans le cadre du projet Predictivity au-delà du périmètre de cette mission.

4. Analyse des enjeux environnementaux et sociétaux

Le FFM ne peut pas être évalué uniquement sur ses performances techniques. Il s'inscrit dans un système sociotechnique plus large, dont les répercussions dépassent largement les frontières des laboratoires ou de l'équipe data. À mesure que l'Intelligence Artificielle s'impose comme levier stratégique dans les grandes organisations, ses implications environnementales, sociétales et éthiques méritent le même niveau d'examen que ses performances. Cette section propose une réflexion critique sur ces dimensions, telles qu'elles se manifestent dans le projet Predictivity et dans la démarche de gouvernance des données conduite au sein de la R&I de L'Oréal.

4.1 Enjeux liés à l'exploitation massive des données

Le projet Predictivity tire sa substance d'un volume important de données. Ce patrimoine scientifique est considérable. Mais son exploitation à grande échelle soulève des questions l'on ne peut se permettre d'ignorer.

La première est celle de la représentativité. Un corpus constitué sur plusieurs décennies reflète les pratiques et les priorités de son époque. Certaines familles de formules, certaines matières premières ou certaines caractérisations peuvent y être

surreprésentés, ou tout simplement absents. Un modèle entraîné sur des données déséquilibrées risque de reproduire ces biais dans ses suggestions, parfois de les amplifier, souvent sans que l'utilisateur en soit conscient. C'est un angle mort structurel, et il doit être adressé dès la phase de constitution du jeu d'entraînement.

La confidentialité est un autre enjeu central. Les formules de composition constituent un avantage concurrentiel majeur pour L'Oréal. Dans le cadre d'un partenariat avec IBM Research, la gestion de ces données propriétaires exige un encadrement rigoureux à chaque maillon de la chaîne : accès, transfert, stockage, aussi bien sur le plan contractuel que technique.

La pertinence temporelle des données, enfin, ne doit pas être négligée. Des formules anciennes peuvent contenir des ingrédients aujourd'hui retirés du marché pour des raisons réglementaires ou environnementales, ou reposer sur des matières premières dont le profil green, tel que renseigné dans le FFM, ne satisfait plus les standards actuels de formulation. Les intégrer sans filtre dans le jeu d'entraînement, c'est exposer le modèle à produire des suggestions non conformes aux exigences actuelles. Ces informations sont ajoutées dans le set de données du FFM.

4.2 Enjeux environnementaux des approches fondées sur l'intelligence artificielle

L'argument environnemental du FFM est réel. En orientant les formulateurs vers des pistes plus prometteuses dès les premières étapes du développement, le modèle peut réduire le nombre d'expérimentations physiques nécessaires réduisant la consommation de matières premières et les dépenses énergétiques associées, et s'inscrivant ainsi dans une démarche de formulation plus durable et écoresponsable.

Mais cette promesse doit être mise en regard du coût énergétique de l'IA elle-même. L'entraînement de grands modèles de fondation mobilise des infrastructures de calcul dont la consommation électrique peut être très élevée (Strubell, 2019). Le FFM de Predictivity est d'une envergure plus modeste, mais la question de son empreinte carbone reste entière et mérite une évaluation rigoureuse à mesure que le projet avance. Le bénéfice environnemental net n'est positif que si les gains obtenus côté laboratoire excèdent effectivement le coût énergétique du modèle : une équation que les engagements du programme L'Oréal for the Future rendent d'autant plus nécessaire à documenter.

Il y a aussi une dimension indirecte, moins visible mais tout aussi réelle : la qualité des données d'entraînement a un impact direct sur le nombre d'itérations nécessaires pour atteindre un niveau de performance satisfaisant. Des données dégradées allongent l'entraînement, donc augmentent sa consommation énergétique. Investir en amont dans la remédiation et la gouvernance contribue ainsi, indirectement, à la sobriété numérique du projet.

4.3 Enjeux sociétaux liés à la fiabilité, à la gouvernance et à la traçabilité des données

Dans le cadre de Predictivity, les suggestions du modèle sont destinées à des formulateurs qui restent décideurs. Cette articulation entre assistance algorithmique et expertise humaine est fondamentale, elle maintient un niveau de contrôle et de jugement critique que l'automatisation seule ne peut pas garantir. Mais à mesure que les performances du modèle s'améliorent et que la confiance en ses suggestions croît, un glissement est possible : les utilisateurs pourraient progressivement réduire leur vigilance, acceptant les recommandations sans les questionner suffisamment. Ce phénomène de sur-délégation est documenté dans de nombreux contextes d'adoption de l'IA en milieu professionnel (Parasuraman, 2010), et le domaine de la formulation n'y est pas imperméable.

Ce risque est amplifié par l'opacité inhérente aux modèles de fondation. Comprendre pourquoi le modèle suggère telle formulation plutôt qu'une autre n'est pas trivial. Le développement d'outils d'explicabilité devient dès lors une nécessité, non pas pour remplacer la confiance, mais pour lui donner une base rationnelle et vérifiable.

La gouvernance des données joue ici un rôle structurant. En établissant des règles claires, documentées et validées collectivement, comme cela a été réalisé lors de la synchronisation des règles métiers avec R2D2. L'équipe data construit un système dont les contraintes sont transparentes et auditable.

Le projet a aussi révélé une réalité moins visible, mais tout aussi déterminante : la complexité humaine d'une telle démarche. Faire dialoguer des Data Engineers, des formulateurs, des data stewards et des managers de qualité autour d'un objet commun ne va pas de soi. Les échanges menés au cours de ce stage pour valider la nature des règles métiers avec les data stewards l'ont illustré concrètement, la gouvernance des données n'est pas qu'un exercice technique. C'est un exercice de construction collective, qui requiert pédagogie, patience, et une capacité réelle à traduire des enjeux complexes dans un langage accessible à chaque partie prenante.

5. Conclusion et perspectives

5.1 Difficultés rencontrées au cours du stage

La première et sans doute la plus concrète des difficultés rencontrées au cours de ce stage a été celle de la compréhension du contexte. Non pas le contexte technique dans un premier temps, mais bien le contexte dans sa globalité : les aspects métiers, les enjeux organisationnels, et les objectifs d'entreprise au sens large.

Arriver dans un projet déjà engagé depuis un an et demi, au sein d'une organisation de la taille de L'Oréal, représente un défi d'intégration que je n'avais pas pleinement anticipé. L'aspect Metier regroupe toutes les activités autour de la formulation cosmétique. Ce domaine possède ses propres logiques, ses propres contraintes, et son propre vocabulaire. Comprendre ce qu'est une formule au sens L'Oréal, appréhender la signification concrète des caractérisations physico-chimiques dans ce contexte de production, distinguer un Contrôle de Stabilité d'une Evaluation Sensorielle, ou encore saisir pourquoi une règle métier générale ne peut pas être confondue avec un cas d'usage Predictivity.

La difficulté s'est également manifestée dans la compréhension du contexte d'entreprise à proprement parler. L'Oréal est une grande entreprise internationale, avec ses propres processus de validation, ses propres chaînes de décision, ses propres outils internes et sa propre culture de travail. Apprendre à naviguer dans cet environnement pour identifier les bons interlocuteurs, comprendre les niveaux de responsabilité, s'adapter aux contraintes d'agenda des Data Stewards, formuler des demandes de manière adaptée selon le profil de chaque partie prenante représente en soi un apprentissage auquel l'école ne prépare que partiellement.

Les premières semaines ont donc été marquées par un volume important de questions, d'allers-retours, de zones d'ombre persistantes et parfois de sentiment d'imposture face à l'ampleur du périmètre. Il m'a fallu accepter de ne pas tout comprendre immédiatement, de poser des questions qui pouvaient paraître élémentaires, et d'avancer malgré l'incertitude, une compétence que je considère aujourd'hui comme l'un des acquis les plus précieux de cette expérience.

5.2 Enseignements tirés de l'expérience

Ce stage m'a apporté un volume considérable d'apprentissages, à la fois techniques, méthodologiques et humains.

Sur le plan technique, j'ai acquis au travers d'exemples concrets et opérationnels dans les sujets que j'ai traités, un certain degré de maîtrise que j'avais jusqu'alors abordés de manière essentiellement théorique : la gouvernance de données, les architectures de données en couches, les pipelines SQL à grande échelle, le linéage des attributs, ou encore les principes fondamentaux de la qualité de données appliquée à l'Intelligence Artificielle. J'ai également découvert des outils et des paradigmes propres au monde industriel : PowerApps, BigQuery sur Google Cloud Platform, l'architecture Medallion, les procédures stockées.

Sur le plan méthodologique, j'ai appris à décomposer un problème complexe en sous-problèmes traitables, à prioriser les actions en fonction de leur impact potentiel, et à documenter mon travail de manière qu'il soit compréhensible et réutilisable par d'autres.

Sur le plan humain et professionnel, j'ai compris que la data, et plus généralement l'ingénierie en milieu industriel, ne se pratique pas en silo. Chaque décision technique entraîne des répercussions sur des parties prenantes qui ne partagent pas nécessairement le même langage ni les mêmes priorités. Savoir traduire un enjeu technique en termes accessibles à un expert métier, négocier une classification de règle avec un Data Steward, ou encore justifier une approche de remédiation auprès d'un manager, ce sont des compétences transverses que ce stage m'a permis de commencer à développer de manière concrète.

5.3 Apport du stage dans le projet professionnel

Ce stage a confirmé et précisé mon orientation professionnelle.

L'intersection entre l'Ingénierie des Données, la Gouvernance, et l'Intelligence Artificielle est un espace qui me correspond. Il requiert à la fois de la rigueur technique, une capacité d'analyse, et une dimension collaborative indispensable. L'expérience acquise au sein de l'équipe data de la R&I L'Oréal m'a donné une première vision réaliste de ce que représente ce type de rôle dans un contexte industriel à grande échelle, avec ses contraintes, ses interdépendances et sa richesse.

Glossaire

Architecture médaille Modèle de structuration des données en trois couches successives, Bronze, Silver et Gold, appliquant un niveau croissant de transformation et de validation. Adoptée dans le projet Predictivity pour répondre progressivement aux exigences de qualité du modèle de fondation.

BOA — Business Object Attribute Attribut d'un Business Object correspondant à une colonne dans une table relationnelle. Niveau de granularité le plus fin de la taxonomie L'Oréal. Dans ce document, les BOA mesurable_ph_code, ph et standard_deviation_ph constituent le triplet central de l'analyse de remédiation.

BO — Business Object Entité de données correspondant à une table relationnelle, quatrième niveau de la taxonomie L'Oréal. Un BO regroupe un ensemble de BOA décrivant un concept métier cohérent.

CDS — Consumption Dataset Dénomination propre au projet Predictivity désignant les couches Bronze et Silver de l'architecture médaille, implémentées sous deux schémas distincts partageant la même appellation.

CTE — Common Table Expression Sous-requête SQL temporaire et nommée, réutilisable dans la requête principale sans créer de table physique persistante. Utilisée pour agréger des sources SDDS hétérogènes avant exposition dans la couche CDS.

Data Steward Responsable métier chargé de définir, valider et maintenir les règles de qualité et les politiques de gouvernance associées à un périmètre de données. Ils en ont l'Ownership. Dans ce projet, les Data Stewards valident la classification de chaque règle entre périmètre général R&I et cas d'usage Predictivity.

EDA — Exploratory Data Analysis Processus collaboratif entre experts métier et ingénieurs des données visant à identifier les anomalies, définir les seuils de validité et produire les règles métiers centralisées dans R2D2.

FFM — Formulation Foundation Model Modèle de fondation développé dans le cadre du projet Predictivity, né d'un partenariat entre la R&I L'Oréal et IBM Research, conçu pour assister les formulateurs dans la génération, l'optimisation et la prédiction des performances de formulations cosmétiques.

GCP — Google Cloud Platform Infrastructure cloud sur laquelle reposent les tables SDDS et CDS du projet Predictivity, accessibles via des identifiants de la forme project.dataset.table dans les requêtes SQL.

Gouvernance de données Ensemble de règles, responsabilités et processus encadrant la gestion des données dans le temps. À distinguer de la remédiation : la gouvernance agit *autour* de la donnée en définissant le cadre et les règles de gestion; la remédiation agit *sur* la donnée en corrigeant ses anomalies.

LLM — Large Language Model Modèle de fondation, entraîné sur de vastes corpus textuels. Le FFM de Predictivity s'en distingue par son entraînement sur des données structurées tabulaires plutôt que sur du texte.

Modèle de fondation Modèle d'apprentissage automatique entraîné à grande échelle sur de vastes volumes de données, généralisable et adaptable à des tâches variées par spécialisation sur un domaine cible.

pH Mesure de l'acidité ou de l'alcalinité d'une solution sur une échelle de 0 à 14. C'est un des paramètres vérifié en formulation cosmétique, il constitue dans ce document l'attribut central de l'analyse et de la remédiation, illustrant la détection d'incohérences entre attributs liés.

Pipeline de données Séquence automatisée de transformations SQL appliquées aux données entre deux couches de l'architecture, assurant la cohérence et la traçabilité des flux de bout en bout.

R2D2 — Référentiel Recipe Data Dictionary PowerApp développée en interne chez L'Oréal centralisant et structurant l'ensemble des règles métiers, classées selon la taxonomie des données avec leur périmètre d'application, leur dimension et leur statut de validation. Son nom est une référence au robot astromécano de *Star Wars*.

Reformulation Démarche de développement cosmétique consistant à améliorer une formule existante en modifiant sa composition ou ses paramètres de procédé, à partir des enseignements tirés de formules antérieures.

Règles métiers — Business Rules Conditions logiques documentant les exigences de qualité applicables à un ou plusieurs attributs, permettant une détection automatisée et systématique des anomalies à grande échelle. Exemple : *SI l'attribut est pH ALORS la valeur doit être comprise entre 0 et 14.*

Remédiation de données Processus de correction ciblée des anomalies identifiées dans les données, agissant directement sur les valeurs des attributs concernés, après validation par les experts métier et implémentation de règles de validation (liste de valeurs, checks, lors de la saisie ou acquisition des données).

Rhéologie Discipline scientifique étudiant l'écoulement et la déformation de la matière sous l'effet de contraintes mécaniques. Les mesures rhéologiques constituent l'un des types de données de caractérisation générées en laboratoire et intégrées dans l'architecture Predictivity.

SDDS — Shared Domain Dataset Système au sein duquel la taxonomie des données L'Oréal prend forme concrètement, présenté sous forme de vues structurées organisées selon la hiérarchie domaine > famille > sous-famille > BO > BOA. Constitue la couche source à partir de laquelle commence le parcours des données dans le projet.

Similarité cosinus Métrique mesurant le cosinus de l'angle entre deux vecteurs, retournant un score entre 0 et 1. Utilisée dans ce document pour apparier automatiquement les descriptions textuelles des règles métiers entre deux fichiers sources sans clé pivot commune.

Sproc — Stored Procedure Ensemble de requêtes SQL précompilées, stockées et exécutables à la demande. Dans ce projet, les sprocs implémentent les règles de qualité dans la couche Silver sous une forme non directement réutilisable dans R2D2, nécessitant une traduction manuelle.

Taxonomie des données Système de classification hiérarchique à cinq niveaux, domaine, famille, sous-famille, Business Object et Business Object Attribute, structurant les données L'Oréal avec des conventions de nommage standardisées pour garantir leur identifiabilité et leur exploitabilité.

TDM — Transversal Data Model Modèle de données créé pour le projet Predictivity, fusionnant des mesures issues de sources hétérogènes telles que Stabelab, Alise, Fizz et ICB en un modèle unifié. Sa complexité structurelle, résultant de l'agrégation de plus de 33 tables SDDS via des dizaines de CTEs imbriquées, en fait le périmètre de cartographie le plus exigeant du document.

Bibliographie

L'Oréal, 2026. *Résultats annuels 2025*, Paris: Groupe L'Oréal.

Parasuraman, R. e. M. D., 2010. Complacency and bias in human use of automation: An attentional integration. p. 381–410.

Reimers, N. e. G. I., 2019. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, p. 3982–3992.

Sambasivan, N. K. S. H. H. A. D. P. P. e. A. L., 2021. Everyone wants to do the model work, not the data work. *Data Cascades in High-Stakes AI*, pp. 1-15.

Strubell, E. G. A. e. M. A., 2019. Energy and Policy Considerations for Deep Learning in NLP. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, p. 3645–3650.

Wand, Y. e. W. R., 1996. *Anchoring data quality dimensions in ontological foundations*, s.l.: Communications of the ACM.

Annexe I

Attribut			Volumetrie de données concernées	Action/Remédiation
measurable_ph_code	ph	standard_deviation_ph		
OUI	NOT NULL	NOT NULL	452660	Aucune action
OUI	NOT NULL	NULL	68883	Changer l'écart-type à 0,3 par défaut
OUI	NULL	NOT NULL	89369	Changer measurable_ph_code à NON (quantité d'eau < 60%) et autres conditions
OUI	NULL	NULL	707892	Changer measurable_ph_code à NON (quantité d'eau < 60%) et autres conditions
NON	NOT NULL	NOT NULL	409	Changer measurable_ph_code à OUI (quantité d'eau > 60%) et autres conditions
NON	NOT NULL	NULL	247	Changer l'écart-type à 0,3 par défaut et measurable_ph_code à OUI (quantité d'eau > 60%) et autres conditions
NON	NULL	NOT NULL	61302	Changer la valeur de l'écart-type à NULL
NON	NULL	NULL	268571	Aucune action
NULL	NOT NULL	NULL	5767	Changer l'écart-type à 0,3 par défaut et measurable_ph_code à OUI (quantité d'eau > 60%) et autres conditions
NULL	NULL	NOT NULL	56288	Changer la valeur de l'écart-type à NULL
NULL	NOT NULL	NOT NULL	58661	Changer measurable_ph_code à OUI (quantité d'eau > 60%) et autres conditions

Annexe II

```

SELECT
    p.formula_code,
    p.measurable_ph_code,
    p.ph,
    p.standard_deviation_ph,
    phc.batch_value_en                                AS norme,
    CAST(l.formula_creation_date AS STRING)            AS
        formula_creation_date,
    l.formula_status_name_en,
    l.active_formula_flag,
    a.formula_type_name_en,
    g.metier_name_en,
    g.formula_creation_laboratory_name_en,
    g.formula_origin_code,
    g.formula_origin_name_en,
    d.open_dev_formula_flag,
    COALESCE(f.has_regulator_mineral_texture, FALSE)    AS
        has_regulator_mineral_texture,
    COALESCE(f.has_agent_osmotique, FALSE)              AS
        has_agent_osmotique,
    COALESCE(f.has_base, FALSE)                        AS has_base,
    COALESCE(f.has_agent_acidifiant, FALSE)            AS
        has_agent_acidifiant,
    COALESCE(f.has_gelifiant, FALSE)                   AS has_gelifiant,
    m.physical_form_name_en,
    fic.total_raw_material_concentration,
    CASE
        WHEN fic.total_raw_material_concentration > 99
            AND fic.total_raw_material_concentration < 101 THEN TRUE
        ELSE FALSE
    END                                                  AS fla_compo_ok_flag
    ,
    SUM(frm.formula_raw_material_concentration_percentage * c.tot_concentration / 100)
        AS water_concentration,
    alc.alcohol_concentration,
    surf.total_surfactant_concentration,
    surf.surfactant_names,
    gly.total_glycol_percentage,
    tai.total_tensioactif_inverse_percentage

FROM 'itg-btdppublished-gbl-ww-pd.btdp_ds_c2_9ab_md_formula_characteristics_eu_pd.
    flc_formula_ph' AS p

LEFT JOIN 'itg-btdppublished-gbl-ww-pd.
    btdp_ds_c2_9aa_md_formula_general_information_eu_pd.fgi_formula_identification_v2'
        AS g ON g.formula_id = p.formula_id
LEFT JOIN 'itg-btdppublished-gbl-ww-pd.
    btdp_ds_c2_9aa_md_formula_general_information_eu_pd.fgi_formula_lifecycle'
        AS l ON l.formula_id = p.formula_id
LEFT JOIN 'itg-btdppublished-gbl-ww-pd.
    btdp_ds_c2_9aa_md_formula_general_information_eu_pd.fgi_formula_subcontracting'
        AS d ON d.formula_id = p.formula_id
LEFT JOIN 'itg-btdppublished-gbl-ww-pd.btdp_ds_c2_9ab_md_formula_characteristics_eu_pd.
    flc_eu_notification_final_product_additional_information' AS m ON m.formula_id
    = p.formula_id
LEFT JOIN 'itg-btdppublished-gbl-ww-pd.
    btdp_ds_c2_9aa_md_formula_general_information_eu_pd.
    fgi_formula_ri_general_classification_v2'
        AS a ON a.formula_id = p
    .formula_id
LEFT JOIN ph_characteristics
        AS phc ON phc.id_formula = p.
    formula_id

```

```

LEFT JOIN formula_total_ingredient_composition AS fic ON fic.formula_id = p.
formula_id
LEFT JOIN formula_raw_materials AS frm ON frm.formula_id = p.
formula_id
LEFT JOIN concentration_data AS c ON c.raw_material_code = frm.
raw_material_code
LEFT JOIN filtered_formula_raw_materials AS sd ON sd.
formula_id = p.formula_id
LEFT JOIN surfactant_data AS surf ON surf.formula_id = p.
formula_id
LEFT JOIN glycol_data AS gly ON gly.formula_id = p.
formula_id
LEFT JOIN tensioactif_inverse_data AS tai ON tai.formula_id = p.
formula_id
LEFT JOIN alcohol_data AS alc ON alc.formula_id = p.
formula_id
GROUP BY
p.formula_code,
p.measurable_ph_code,
p.ph,
p.standard_deviation_ph,
phc.batch_value_en,
l.formula_creation_date,
l.active_formula_flag,
l.formula_status_name_en,
a.formula_type_name_en,
g.metier_name_en,
g.formula_creation_laboratory_name_en,
g.formula_origin_code,
g.formula_origin_name_en,
d.open_dev_formula_flag,
f.has_regulator_mineral_texture,
f.has_agent_osmotique,
f.has_base,
f.has_agent_acidifiant,
f.has_gelifiant,
m.physical_form_name_en,
fic.total_raw_material_concentration,
surf.total_surfactant_concentration,
surf.surfactant_names,
gly.total_glycol_percentage,
tai.total_tensioactif_inverse_percentage,
alc.alcohol_concentration

HAVING water_concentration > 60

ORDER BY p.formula_code

```

```

WHERE
UPPER(p.measurable_ph_code) IS NULL
AND p.ph IS NOT NULL
AND p.standard_deviation_ph IS NOT NULL

```


Annexe III

SDDS					CDS							
Data Set	Table/View	Field	Data Type	PK	Table/View	Field	Data Type	PK	Calculated GCP	Detail Calculation GCP	Category	Description
btdp_ds.c2.9ff_rm_pcp.eu_pd	rmp_tested_sample	tested_sample_ms_id	STRING	Yes	rmp_sample	tested_sample_ms_id	STRING	Yes	No		Output	
btdp_ds.c2.9ff_rm_pcp.eu_pd	rmp_tested_sample	ri_data_confidentiality	NUMERIC	No				No	Yes	ri_confidentiality = 0	Condition	
SDDS					CDS							
Data Set	Table/View	Field	Data Type	PK	Table/View	Field	Data Type	PK	Calculated GCP	Detail Calculation GCP	Category	Description
btdp_ds.c2.9ea_instrumental_evaluation.eu_pd	iev_descriptive_statistics.v2	study_design_code	STRING	Yes	tdm_result	result_id	STRING	Yes		concat(study_design_code, "#", evaluation_output_code, "#AVERAGE") AS result_id	CTE, Output	results_iev
btdp_ds.c2.9ea_instrumental_evaluation.eu_pd	iev_descriptive_statistics.v2	evaluation_output_code	STRING	Yes	tdm_result	result_id	STRING	Yes		concat(study_design_code, "#", evaluation_output_code, "#AVERAGE") AS result_id	CTE, Output	results_iev
btdp_ds.c2.9ea_instrumental_evaluation.eu_pd	iev_descriptive_statistics.v2	average	NUMERIC	No	tdm_result	result_value_numeric	NUMERIC	No			CTE, Output	results_iev
btdp_ds.c2.9ea_instrumental_evaluation.eu_pd	iev_descriptive_statistics.v2	evaluation_output_code	STRING	Yes				Yes		evaluation_output_code IS NOT NULL	CTE, Condition	results_iev
btdp_ds.c2.9ea_instrumental_evaluation.eu_pd	iev_descriptive_statistics.v2	average	NUMERIC	No				Yes		average IS NOT NULL	CTE, Condition	results_iev
					tdm_result	result_id	STRING	No			Output	
					tdm_result	result_value_numeric	NUMERIC	No			Output	